

用于多区域 HVAC 设施的偏差补偿 Q-Learning 控制器开发

Syed Ali Asad Rizvi, Member, IEEE, Amanda J. Pertzborn, 和 Zongli Lin, Fellow, IEEE

摘要——我们提出了一种偏差补偿强化学习 (RL) 算法的开发, 该算法在存在不可测扰动和未知动力学的多区域供暖、通风与空调 (HVAC) 实验设施中, 优化热舒适性 (通过最小化跟踪误差) 和控制使用量 (通过惩罚设定点偏差)。研究表明, 不可测扰动的存在会导致传统 RL 控制器中的学习方程不一致, 从而引起参数估计偏差 (即使有积分作用支持), 在极端情况下还会导致学习算法发散。我们通过将流行的 Q-learning 算法应用于多区域 HVAC 环境的线性二次调节 (LQR) 来展示这一问题, 并表明, 即使有积分支持, 当 HVAC 扰动由于未知热增益、占用变化、光源以及室外天气变化而不可测时, 该算法在学习阶段仍会表现出偏差问题。为了解决这一困难, 我们提出了一种偏差补偿学习方程, 该方程在学习最优控制参数的同时, 学习由扰动 (以及可能的其他来源) 产生的集总偏差项。实验结果表明, 所提出的方案不仅恢复了无偏差的最优控制参数, 而且无需显式学习动态模型或估计扰动即可实现这一点, 证明了该算法在应对上述挑战方面的有效性。

美国电力消耗的约 76% [3]。最优控制理论为设计满足规定性能和成本目标的控制器提供了框架。诸如模型预测控制 (MPC) 这样的最优控制器在 HVAC 控制中很受欢迎, 尽管它们涉及复杂的设计过程, 需要相当准确的 HVAC 模型以及对外部扰动的估计 [4]。

近年来, 特别是在过去五年中, HVAC 控制文献已转向基于人工智能 (AI) 的方法 [5] 来设计最优控制器。强化学习 (RL) 框架是一种基于 AI 的最优决策范式, 并被认为是机器学习 (ML) 的三大支柱之一, 另外两个是监督学习和无监督学习 [6]。RL 是 HVAC 控制中一个有前景的候选方法, 因为它能够在不求解传统的基于模型的优化问题的情况下学习最优控制策略 [7]。与基于调参的比例-积分-微分 (PID) 控制 [8] 和基于 ML 的系统辨识方法相比, 无模型 RL 是一种直接自适应控制方法, 它在不学习底层系统模型的情况下学习最优控制动作 [9]。因此, 无模型 RL 控制不同于基于两步学习的 MPC 方法, 后者基于学习到的模型执行优化。

索引词——HVAC 控制, 最优跟踪, Q-learning, 强化学习 (RL)。

1. 引言 使建筑既能让 occupants 感到舒适又能节能的一种有前景的方法, 是通过供、通风与空调 (HVAC) 系统进行最优控制 [1]。HVAC 系统的最优控制对我们的社会具有实际意义, 因为人们几乎 85% 的时间都在建筑物内度过 [2]。建筑占

近年来, 基于 RL 的 HVAC 控制文献在不同控制层级上不断增长, 范围从部件级控制 [10] - [12] 到系统级控制 [13] - [15]。文献 [16] 对近期研究进行了全面综述。尽管 RL 控制文献在处理带约束的非线性问题方面取得了显著发展 [17], 但无模型 RL 的一个缺点是, 最优决策往往是一种完全黑箱的操作, 并且没有利用 HVAC 系统的物理洞察。因此, 学习过程往往较长, 所得控制缺乏直观性 [10], [18]。RL 在 HVAC 控制中的早期应用已经展示出不错的控制性能, 但代价是学习时间显著较长 [19], [20]。在 [21] 中, 将基于黑箱 RL 的 HVAC 控制与开关控制和 Fuzzy-PD 控制进行了比较, 结果表明, 尽管 RL (在热舒适性方面) 表现更优, 但穷尽式探索需要较长的训练周期, 并无意中限制了性能增益。为了解决这一困难, 一些研究人员探索了降维方法以加速学习 [22] - [24]。也有研究提出了基于事件的方法以减少学习时间 [25]。系统的物理洞察可以提供

稿件于 2023 年 3 月 6 日收到; 2023 年 4 月 12 日修订; 2023 年 4 月 18 日接受。本工作部分受到 NIST (70NANB18H161) 的支持。由副编辑 Qing-Long Han 推荐。(通信作者: Zongli Lin。)

引用: S. A. A. Rizvi, A. J. Pertzborn, and Z. Lin, "Development of a bias compensating Q-learning controller for a multi-zone HVAC facility," IEEE/CAA J. Autom. Sinica, vol. 10, no. 8, pp. 1704-1715, Aug. 2023.

S. A. A. Rizvi 任职于 Department of Electrical and Computer Engineering, Tennessee Technological University, Cookeville, TN 38505 USA (e-mail: srizvi@tntech.edu)。

A. J. Pertzborn 任职于 National Institute of Standards and Technology (NIST), Gaithersburg, MD 20899 USA 的 Building Energy and Environment Division 下属 Mechanical Systems and Controls Group (e-mail: amanda.pertzborn@nist.gov)。

Z. Lin 任职于 University of Virginia, Charles L. Brown Department of Electrical and Computer Engineering, Charlottesville, VA 22904-4743 USA (email: z15y@virginia.edu)。

本文中多个彩色版本的彩色版本可在线获取, 网址为 <http://ieeexplore.ieee.org>。

Digital Object Identifier 10.1109/JAS.2023.123624

关于控制问题结构的有价值信息。将 HVAC 动力学的一部分知识与 RL 相结合的思想最近已被考虑 [26], [27]。传统 PID 控制成功的主要原因之一是控制参数的调整是透明的。然而, 它没有用于优化给定目标函数的正式设计流程。另一方面, 诸如线性二次调节器 (LQR) 之类的最优控制方法求解涉及某个用户定义代价函数的优化问题。RL 已被成功用于求解这类最优控制问题。分布式多智能体技术也正被纳入 RL 中, 持续增强其固有能力 [28]。

已经提出了基于 RL 的无模型学习方法, 用于求解涉及扰动的最优控制问题。近期两种流行的用于处理扰动抑制的无模型最优控制方法, 涉及将这些学习方法分别与博弈论 [29] 和输出调节 [30] 框架相结合。零和博弈表述已在 [31]、[32] 中提出。近期还提出了这些基于博弈论的扰动抑制设计的逆 RL 扩展 [33]、[34]。在上述框架中处理扰动的一个关键困难是, 通常假设扰动是可测量的, 以防止学习方程相对于系统动力学出现任何不匹配 [29]。如果不加以考虑, 未知扰动会导致不一致的学习方程, 最终导致估计偏差, 并可能使闭环系统不稳定。

本文针对多区域实验室设施中不可测扰动的问题进行研究, 这些扰动可能导致控制估计中的偏差 (甚至不稳定)。结果表明, RL 算法能够学习满足给定最优性准则的控制动作。为实现所提出方案的实际应用, 采用了一系列设计考虑。这包括在不需要仿真数据源的情况下, 相比黑箱 RL 方法减少学习时间。文中讨论了不同激励信号在满足 RL 探索权衡方面的现实影响, 以及数值求解器在所提出算法开发中的作用。

本文的主要贡献如下。我们在美国国家标准与技术研究院 (National Institute of Standards and Technology, NIST) 的一个多区域商业配备 HVAC 测试设施中, 给出了一种新型偏差补偿强化学习算法的设计与实现方面。鉴于建筑物对我们的能源足迹具有显著影响, 工业 HVAC 系统非常适合利用此类 AI 算法的能力。本文的动机在于, 通过呈现对实现这些算法至关重要的各种实现方面, 加速此类基于学习的最优控制算法在商业环境中的主流工业接受度。我们认为, 我们的工作少数考虑 RL 控制文献中发现的由扰动引起的偏差这一关键现象的实验研究之一, 我们通过以下方式加以处理:

增强学习方程并引入偏差补偿机制。我们的研究表明, 偏差问题可能导致次优性和不稳定性; 通过采取本文提出的措施, 可以在不需要模型辨识和扰动估计阶段的情况下防止该问题。

本文其余部分组织如下。Section II 给出了区域级 HVAC 控制的控制表述。Section III 提出了扰动补偿 Q-learning 算法的设计。Section IV 描述了测试设施和实验设置的细节。Section V 给出了本研究的实现方面和结果。Section VI 总结全文。

II. 问题表述 我们将区域级控制问题表述为一种可由结构化 RL 控制器处理的数学形式。注意, 学习算法本身既不需要了解区域模型参数, 也不需要了解不可测量的负载扰动。相反, 它在以下小节中介绍的控制结构内学习最优参数。

A. 区域动态

我们考虑一种区域模型, 该模型捕捉了实现我们的设计目标所需的复杂度水平, 即基于规定的加权跟踪误差和设备设定点偏差来调节区域热舒适性。为此, 我们采用以下基于常微分方程的 HVAC 区域标准动态模型 [35]:

$$\begin{aligned}\frac{dT_z}{dt} &= \frac{f_{sa}\rho_a C_{pa}}{C_z} (T_{sa} - T_z) + 2 \frac{U_{wew} A_{wew}}{C_z} (T_{wew} - T_z) \\ &\quad + 2 \frac{U_{wns} A_{wns}}{C_z} (T_{wns} - T_z) + \frac{q}{C_z} \\ \frac{dT_{wew}}{dt} &= \frac{U_{wew} A_{wew}}{C_{wew}} (T_z - T_{wew}) + \frac{U_{weo} A_{weo}}{C_{wew}} (T_o - T_{wew}) \\ \frac{dT_{wns}}{dt} &= \frac{U_{wns} A_{wns}}{C_{wns}} (T_z - T_{wns}) + \frac{U_{wno} A_{wno}}{C_{wns}} (T_o - T_{wns}).\end{aligned}$$

Table I
包含变量和常数参数的说明。通过定义状态向量、控制输入和扰动向量, 上述区域模型可以表示为紧凑的矩阵形式。所得状态空间模型为

$$\frac{dx(t)}{dt} = \mathcal{A}x(t) + \mathcal{B}u(t) + \mathcal{D}d(t).$$

(1)

中的状态空间模型需要进行 (时间) 离散化, 以便进行数字实现, 同时也是由于本文所考虑的强化学习算法的离散性质。可以使用标准 Euler 离散化方法得到如下离散时间状态空间模型:

$$x_{k+1} = \mathcal{A}x_k + \mathcal{B}u_k + \mathcal{D}d_k$$

(2)

其中 k 为离散时间索引, 离散化矩阵计算为 $\mathcal{A}_d$, 以及 $\mathcal{B}_d$, 其中 Δt 为采样周期。维

TABLE I 术语表

符号	描述
A_{ew} m ²	东/西墙面积 ()
A_{wns} m ²	北/南墙面积 ()
C_{pa} kJ/kgC	空气比热 ()
C_{wew} kJ/C	东/西墙热容 ()
C_{wns} kJ/C	北/南墙热容 ()
C_z kJ/C	区域的热容 ()
$\dot{V}_{fsa}$ m ³	送风的体积流量 ()
q_w W	来自人员、照明、门的热增益 (瓦特) ()
T_o C	室外温度 (摄氏度) ()
T_{sa} C	送风温度 (摄氏度) ()
T_{wew} C	东/西墙的温度 (摄氏度) ()
T_{wns} C	北/西墙温度 (摄氏度) ()
T_z C	区域温度 (摄氏度) ()
U_{wew} W/m ² C	东/西墙传热系数 ()
U_{wns}	Heat transfer coefficient of North/West walls (W/m ² C)
ρ_a	Density of air (Kg/m ³)

(2) 中矩阵的维度与 (1) 中变量定义的维度相兼容。

B. 控制结构

我们关注的是维持热舒适性，为此我们使用温度跟踪误差，

$$e_k = T_{z_k} - T_{r_k}$$

作为度量，其中为参考温度。目标是为执行器（空气处理机组或变风量（VAV）箱——见 Section IV）找到一个最优控制设定点，以保证渐近温度跟踪，即，同时最小化如下形式的二次代价函数，

$$J = \sum_{i=0}^{\infty} (Q_e e_i^2 + R \tilde{u}_i^2) \tag{3}$$

其中和是标量权重，分别惩罚作为热舒适性度量的温度误差以及相对于稳态的设定点偏差（作为控制作用的度量），其中为送风温度或 VAV 箱的稳态设定点。

我们采用一种标准的比例积分控制结构，最终希望 RL 算法学习到该结构。注意，选择这种结构并不是对强化学习算法的限制。例如，除了遵循比例积分结构外，我们还可以采用其他结构，如前馈控制。为此，我们引入一个新的状态来累积跟踪误差，这是连续时间情形中所用积分作用的离散时间等价形式。基于这一新状态，我们形成如下增广系统：

$$\begin{aligned} x_{k+1} &= Ax_k + Bu_k + Dd_k \\ w_{k+1} &= w_k + e_k \end{aligned} \tag{4}$$

which can be represented compactly in terms of the augmented state vector $X_k = [x_k^T \ w_k^T]^T$,

$X_{k+1} = \bar{A}X_k + \bar{B}u_k + \bar{D}d_k + \bar{R}r_k$ (5) $r_k = T_{r_k} - A, \bar{B}, \bar{D}$ 其中是如前所定义的区域参考设定点，矩阵和可由 (4) 直接获得。该增广形式的代价函数由 (3) 得到如下：

$$J = \sum_{i=0}^{\infty} (\tilde{x}_i^T Q \tilde{x}_i + \tilde{u}_i^T R \tilde{u}_i) \tag{6}$$

where $Q = \begin{bmatrix} C^T Q_e C & 0 \\ 0 & Q_w \end{bmatrix}$, $C = [1 \ 0 \ 0]$ and $\tilde{X}_i = X_i - X_{ss}$ for 某个稳态。对于 (5) 和 (6) 中的问题，存在一个唯一的最优控制器，其形式为

$$u_k^* = -(R + \bar{B}^T P^* \bar{B})^{-1} \bar{B}^T P^* \bar{A} X_k = -K^* X_k \tag{7}$$

P ，其中是代数 Riccati 方程 (ARE) [36] 的唯一正定解，

$$\bar{A}^T P \bar{A} - P + Q - \bar{A}^T P \bar{B} (R + \bar{B}^T P \bar{B})^{-1} \bar{B}^T P \bar{A} = 0. \tag{8}$$

注意，该权重被包括进来以加权误差的积分（求和）。该权重惩罚积分（求和）状态相对于稳态的偏差。由于积分（求和）在闭环系统中引入了不稳定模态，因此需要为正定。该最优控制器的详细推导可见 [37]。

III. 偏差补偿强化学习控制器 上一节介绍了用于 HVAC 区域动力学的控制结构。然而，该控制设计涉及对区域动力学的了解，而这些通常不可获得。处理此类设计问题的传统方法是采用系统辨识或自适应控制技术。与这些方法不同，强化学习具有基于预先规定的最优性准则直接学习控制动作或控制结构（如本文中的情况）的潜力。在本节中，我们有兴趣采用强化学习来学习上一节中介绍的控制结构。具体而言，我们采用了我们近期工作 [37] 中开发的一种扰动补偿 Q-learning 算法。

A. 奖励函数

强化学习控制器设计的一个关键部分是适当选择奖励（或惩罚/效用）函数。长期成本基于该函数进行评估。由于长期成本无法预先知道（因为区域动力学是未知的），从奖励函数获得的即时奖励主要用于驱动强化学习算法学习最优控制策略。从强化-

强化学习算法对应于奖励函数的一种特定选择。因此，奖励函数应能够捕捉我们要处理的控制目标的本质。用于学习基于最优控制公式的预定义控制结构的奖励函数，可以很容易地从代价函数中得到。对于我们特定的基于积分（求和）的控制结构，它是热性能和控制利用率的瞬时二次代价，

$$\mathcal{R}_k = X_k^T Q X_k + u_k^T R u_k \quad (9)$$

其中，热舒适性由如前所定义的增广矩阵 Q 加权。注意，权重 R 与之前保持相同，因为它不受增广过程的影响。

B. 扰动补偿 Q-函数

在这项工作中，我们将 Q-learning 作为主要的 RL 算法，这是由于其无模型能力以及其在学习最优控制器方面的成功。RL 控制文献中大多数处理扰动抑制的学习算法，在学习阶段都涉及对扰动的测量（甚至操纵）。在我们的问题设定中，扰动来自各种热增益来源以及室外温度变化。因此，通常无法获得对扰动的测量。我们最近的工作 [37] 表明，如果不对这些扰动加以考虑，可能会导致从标准 Q-learning 算法学习到的控制策略产生偏差。采用以下 Q 函数定义 [38] 中的动态方程 (5)：

$$Q_K = X_k^T Q X_k + u_k^T R u_k + V_K(X_{k+1}) \quad (10)$$

where $V_K(X_{k+1}) = X_{k+1}^T P X_{k+1}$ is the quadratic value function. Substituting it, along with (5), in (10) results in

$$Q_K = \begin{bmatrix} X_k \\ u_k \\ r_k \end{bmatrix}^T \begin{bmatrix} Q + \bar{A}^T P \bar{A} - \bar{A}^T P \bar{B} - \bar{A}^T P \bar{R} \\ \bar{B}^T P \bar{A} - R + \bar{B}^T P \bar{B} - \bar{B}^T P \bar{R} \\ \bar{R}^T P \bar{A} - \bar{R}^T P \bar{B} - \bar{R}^T P \bar{R} \end{bmatrix} \begin{bmatrix} X_k \\ u_k \\ r_k \end{bmatrix} + 2X_k^T \bar{A}^T P \bar{D} d_k + 2u_k^T \bar{B}^T P \bar{D} d_k + 2r_k^T \bar{R}^T P \bar{D} d_k + d_k^T \bar{D}^T \bar{P} \bar{D} d_k \triangleq (z'_k)^T H' z'_k + 2X_k^T \bar{A}^T \bar{P} \bar{D} d_k + 2u_k^T \bar{B}^T \bar{P} \bar{D} d_k + 2r_k^T \bar{R}^T \bar{P} \bar{D} d_k + d_k^T \bar{D}^T \bar{P} \bar{D} d_k \quad (11)$$

其中，涉及不可测信号的最后四项会导致估计偏差。为了解决这一困难，我们提出了一种带扰动补偿的 Q-learning 算法，该算法可防止在学习阶段出现偏差。引入偏差补偿项的动机来源于偏差效应本身，该效应由上述 Q-function 中包含不可测扰动的项所诱发。因此，在常规 Q-function 中增广一个偏差因子 c ，可补偿缺失的扰动项，并防止其余项中出现估计偏差。这涉及设计如下带有偏差补偿项的 Q-function：

$$Q_K = \begin{bmatrix} X_k \\ u_k \\ r_k \\ c \end{bmatrix}^T \begin{bmatrix} Q + \bar{A}^T P \bar{A} - \bar{A}^T P \bar{B} - \bar{A}^T P \bar{R} & b_1 \\ \bar{B}^T P \bar{A} - R + \bar{B}^T P \bar{B} - \bar{B}^T P \bar{R} & b_2 \\ \bar{R}^T P \bar{A} - \bar{R}^T P \bar{B} - \bar{R}^T P \bar{R} & b_3 \\ b_1^T & b_2^T & b_3^T & b_4 \end{bmatrix} \begin{bmatrix} X_k \\ u_k \\ r_k \\ c \end{bmatrix} \triangleq \begin{bmatrix} X_k \\ u_k \\ r_k \\ c \end{bmatrix}^T \begin{bmatrix} H_{XX} & H_{Xu} & H_{Xr} & b_1 \\ H_{uX} & H_{uu} & H_{ur} & b_2 \\ H_{rX} & H_{ru} & H_{rr} & b_3 \\ b_1^T & b_2^T & b_3^T & b_4 \end{bmatrix} \begin{bmatrix} X_k \\ u_k \\ r_k \\ c \end{bmatrix} = z_k^T H z_k \quad (12)$$

其中，子矩阵按照前述矩阵中出现的系统矩阵和代价矩阵来定义。因子 c 是偏差缩放因子，是为模拟偏差效应而引入的虚拟因子。感兴趣的读者可参阅 [37] 了解此类 Q-function 的详细信息。值得指出的是，上述 Q-function 具有明确定义的二次结构，该结构对应于我们在 Section II-B 中给出的控制结构选择。给定区域动态，Q-function 提供了遵循某一控制策略的长期代价度量。由于区域动态未知，因此采用 Q-learning 算法来学习 Q-function，并基于估计的 Q-function 改进控制策略。

C. Q-Learning 算法

在本节中，我们提出一种迭代 Q-learning 算法，用于估计 (12) 中定义的二次结构 Q-function。该迭代算法基于强化学习文献 [39] 中的策略迭代算法。不同于标准的基于策略迭代的 Q-learning 算法 [38]，该算法旨在学习在作用于区域的未知负载扰动条件下的最优策略（比较见 [37]）。Q-learning 方程是用于学习 Q-function 和最优策略的关键方程，其给出如下：

$$z_k^T H z_k = X_k^T Q X_k + u_k^T R u_k + z_{k+1}^T H z_{k+1}. \quad (13)$$

Algorithm 1 扰动补偿状态反馈 Q-Learning 策略迭代算法

输入：输入-状态数据

output: H^*

1: **initialize.** Select a stabilizing initial policy $u_k^0 = -K^0 X_k + v_k$ with v_k being an exploration signal. Set the iteration index $j = 0$.

(X_k, u_k, r_k) 2: 获取数据。施加输入以收集的数据集。3: 重复 4: 策略评估。确定 $\bar{z}_k$ 的最小二乘解

$$(\bar{H}^j)^T (\bar{z}_k - \bar{z}_{k+1}) = X_k^T Q X_k + u_k^T R u_k.$$

5: 策略改进。将改进后的策略确定为

$$K^{j+1} = (H_{uu}^j)^{-1} (H_{ux}^j).$$

6: Increment index $j \rightarrow j + 1$

7: **until** $\|K^j - K^{j-1}\| < \varepsilon$ for some small $\varepsilon > 0$.

Algorithm 1 是一种用于区域级 HVAC 控制的策略迭代 Q-learning 算法。这本质上是一个两步过程。在策略评估步骤中，我们使用关键方程 (13) 来求解未知向量 $\bar{H}$ 。在策略更新步骤中，我们执行一步策略改进，其本质上最小化在策略更新步骤中获得的 Q 函数估计值。这两个步骤重复进行，直到满足收敛准则 ε 。感兴趣的读者可参考 [37] 了解该算法的收敛性证明。

D. Bellman 方程的求解器

Q-learning 算法中的一个关键步骤是通过估计 Q 函数来评估策略值。在我们的问题中，这涉及通过求解 Bellman 方程 (13) 来估计矩阵 $\bar{H}$ (作为去除重复项后的向量)。尽管 Bellman 方程关于未知量是线性的，但它是欠定的。批量最小二乘 (LS) 和递归最小二乘 (RLS) 等求解器通常用于求解 Bellman 方程。在本研究中，我们比较 LS 和 RLS 求解器，以观察由求解器引起的估计变化。

对于批量最小二乘求解器，我们收集的数据样本，以形成数据矩阵 Φ 和 Υ ，其定义为

$$\Phi = \begin{bmatrix} \bar{z}_{k-L+1} - \bar{z}_{k-L+2} & \bar{z}_{k-L+2} - \bar{z}_{k-L+3} & \cdots & \bar{z}_k - \bar{z}_{k+1} \end{bmatrix}$$

$$\Upsilon = \begin{bmatrix} X_{k-L+1}^T Q X_{k-L+1} + u_{k-L+1}^T R u_{k-L+1} \\ X_{k-L+2}^T Q X_{k-L+2} + u_{k-L+2}^T R u_{k-L+2} \\ \vdots \\ X_k^T Q X_k + u_k^T R u_k \end{bmatrix}$$

$\bar{z}$ ，其中 $\bar{z}$ 是二次基。然后，(13) 的最小二乘解由下式给出

$$\bar{H}^j = (\Phi \Phi^T)^{-1} \Phi^T \Upsilon \quad (14)$$

其中 $\bar{H}$ 是未知向量的估计。由于 $\bar{H}$ 与 $\bar{z}$ 线性相关，(14) 将不具有唯一解，而唯一解是收敛到最优参数所必需的。为克服这一问题，在 $\bar{z}$ 中加入激励噪声 (仅在学习阶段)，以保证 (14) 具有唯一解，即确保满足以下秩条件：

$\rho(\Phi) = 1/(1+1)/2$ 。 (15) u_k 值得注意的是，中的激励将无法操纵偏置缩放因子 c 。然而，该因子很容易调整，例如，通过在连续区间选择不同的常数。这将防止回归向量中出现零项，并确保上述秩条件得到满足。显然，秩条件 (15) 是获得最优解所必需的，而该最优解是最小二乘问题 (14) 的唯一解。

递归最小二乘主要用于促进最小二乘求解器的在线实现。在本文中，我们考虑了以下递归最小二乘实现：

$$\mathcal{E}_k(i) = \mathcal{R}_k - \Phi_k^T(i) \bar{H}(i-1) \quad (16)$$

$$\bar{H}(i) = \bar{H}(i-1) + \frac{P_k(i-1) \Phi_k \mathcal{E}_k(i)}{1 + \Phi_k^T P_k(i-1) \Phi_k} \quad (17)$$

$$P_k(i) = P_k(i-1) - \frac{P_k(i-1) \Phi_k \Phi_k^T P_k(i-1)}{1 + \Phi_k^T P_k(i-1) \Phi_k}$$

$$P_k(0) = P_0 \quad (18) \quad P_0 = \beta I \quad \beta > 0 \quad \Phi_k = \bar{z}_k - \bar{z}_{k+1}$$

其中，对于某个非常大的 β 和 $\bar{z}$ 。该算法的收敛性是在持续激励 (PE) 条件 [40] 下建立的，该条件保证数据足够丰富 [41]。通过在学习阶段向控制信号中注入探索噪声，可以满足该 PE 条件。

IV. 测试设施与实验设置

如 Fig. 1 所示，Intelligent Building Agents Laboratory (IBAL) 旨在模拟小型商业建筑中的 HVAC 系统和建筑负载，但本研究仅使用了该设施的一小部分 (有关 IBAL 的详细信息见 [42] - [45])。Table II 给出了关键设备的规格，其标签与 Fig. 1 相对应。Fig. 2 显示了 IBAL 中大部分空气系统；D 是一个风阀，用于帮助控制通过系统各分支的空气流量。AHU1 和 AHU2 是空气处理机组，它们从室外和各区域 (回风) 取风，并对其进行处理以供各区域使用，即冷却和除湿。每个 AHU 为两个区域处理空气，但这两个区域并不一定具有相同的冷却需求。VAV 允许通过调节空气流量和/或对来自 AHU 的空气进行再热，来针对特定区域对共用 AHU 空气进行调整。因此，在商业 AHU-VAV 系统中，一个控制决策是供应到各区域的空气温度。在本研究中，我们将进入 VAV (来自 AHU) 的温度控制在约 $C (F)$ ，然后使用 VAV 中的电加热器来生成指定的设定点温度




Fig. 1. 智能建筑智能体实验室 (IBAL) 概览。

TABLE II 设备规格

1 室外空气机组
2 空气处理机组 (2x, 15.5 kW)
3 变风量箱 (4x)
4 区域隔间 (4x)
5 冷凝回路
6 冷水机组 (2x, 26.6 kW 和 53 kW)
7 热能





Fig. 2. IBAL 中空气系统概述。

进入区域的空气。该目标设定点由手动调节的 PI 控制器或 RL 算法生成。这并不完全等同于真实商业建筑中的控制工作方式，但我们选择这种简化方法作为 RL 控制算法的概念验证。

涉及 RL 控制器和 VAV-Zone 子系统的基本反馈回路如 Fig. 3 所示。VAV 下游的设定点温度，是基于区域设定点温度，与实际区域温度，之间的误差确定的。VAV 加热器具有其自身的本地 PI 回路（未示出），其运行速率快于控制加热器以使实际温度，更接近的 RL 回路。RL 算法学习用于计算的控制器增益。



Tsa, SP 图 3. RL 控制回路，其根据区域温度进行计算并反馈至 VAV 加热器控制信号。

V. 实现、结果与讨论 本节展示了实现细节以及

所提出的 Q-learning 方案的结果。奖励函数参数决定了跟踪误差和设定点偏差的相对权重。在本研究中，我们分别为跟踪误差、积分（求和）误差和控制力度选择参数为、和。对于离散时间实现，我们发现一分钟的采样周期适用于我们的应用。在我们的实验设置中，由于各区域之间设置了隔热层，墙体的耦合系数可以忽略不计。因此，与墙体温度对应的状态在学习过程中未被使用（尽管所提出的 RL 结构可以完全适应这一点，如我们的仿真研究 [37] 所示）。因此，对于状态反馈结构，我们仅包括区域温度的反馈测量值。

RL 算法中的一个重要考虑因素是，需要通过探索信号充分探索状态-动作空间，以学习最优控制动作 [6]。为此，基于探索的类型和幅值生成了多种数据集。我们考虑了两种最常用的探索信号：1) 具有不同频率和幅值的正弦信号；2) 具有不同方差的高斯信号。从批量 LS 和递归 LS 求解器获得的最终估计结果相同，因此我们仅展示递归 LS 求解器的图。请注意，在收集训练数据集时，一个可工作的稳定控制器（不一定是最优控制器）已经在运行，以满足 PI 算法的初始稳定化要求，并确保数据集处于各区域的预期运行范围内。我们将这一学习阶段称为预学习阶段，也称为探索阶段，因为它涉及训练数据集的生成。另一方面，采用已学习控制器投入运行的阶段称为后学习阶段。Algorithm 1 中的学习迭代正是在这两个阶段中执行的。虽然 Table II 中包含了所有四个区域的结果，但当各区域表现出相似行为时，图中仅展示 Zones 1 和 2。

在实现 RL 算法之前，我们测试了一个手动调谐的 PI 控制器，以了解典型增益和响应。与遵循某一奖励函数来计算增益的 RL 算法不同，该 PI 控制器不考虑任何特定的最优性准则。经过仔细调谐，所使用的比例增益和积分增益的值分别为 10 和 1.5。在这些手动增益下，四个区域的区域温度和设定点变化相似。Fig. 4 显示了 Zones 1 和 2 的响应。

从 RLS 求解器开始，我们将 Algorithm 1 应用于四个区域，使用了两个数据集，这些数据集是通过具有多个频率分量、不同幅值的正弦探索生成的。此情况下的探索信号形式为

$$n_k = A(0.01 \sin(k) + 0.05 \sin(3.1k) + 0.03 \sin(5.3k) + 0.02 \cos(2.3k) + 0.07 \cos(7.3k) + 0.04 \cos(4.3k) + 0.01 \cos(3.9k) + 0.02 \cos(11.9k) + 0.03 \cos(13.9k))$$

(19)




Fig. 4. 手动调谐的 PI 控制器对参考温度的响应, Zone 1 (左) 和 Zone 2 (右)。

对于和, 其分别对应于正弦探索数据集 S1 和 S2。选择这种探索信号是基于实验观察, 在学习阶段获得了令人满意的响应。根据这些响应, 次谐波频率和幅值被任意选取。后续讨论将解释各种探索如何影响收敛性。注意, 这些探索被添加在任何初始稳定控制器之上; 在我们的案例中, 该控制器只是手动调谐的 PI 控制器。我们使用向量记法来表示增益 (见 Table III), 其中第一个分量为比例增益, 第二个分量为积分分量。因此, 初始增益向量被设为。在应用 Algorithm 1 之前, 我们首先使用正弦数据集在无偏置补偿的情况下学习控制增益。Zones 1-4 的结果显示在 Table III 的前两行中, 表明未收敛。事实上, 从这些控制增益的符号可以看出, 它们并不能使系统稳定。这表明, 在存在扰动情况下, 常规的无补偿 Q-learning LQR 算法会受到偏置的影响。现在, 我们继续使用两个正弦探索数据集, 采用带偏置补偿的 Algorithm 1。使用 S1 和 S2 两个数据集时, Zone 1 在学习阶段的响应如 Fig. 5 所示。

对于两个数据集, Zone 1 的学习后响应和参数估计的收敛情况分别如 Figs. 6 和 7 所示。通过比较这些图, 我们发现参数估计的收敛取决于探索的幅度。这是可以预期的, 因为 RL 算法的收敛性会随状态-动作空间被探索的程度而变化。现在, 我们将上述 Zone 1 的收敛结果与 Zone 2 的结果进行比较。Zone 2 针对数据集 S1 和 S2 的学习前响应如 Fig. 8 所示, 而学习后响应如 Fig. 9 所示。Zone 2 的参数在不同探索条件下也表现出收敛, 如 Fig. 10 所示。Zone 2 学到的控制增益也与 Zone 1 非常接近, 表明二者具有几乎相同的动态环境。类似的观察也

出现在其余区域中 (仅显示了 Zones 1 和 2 的图)。

Remark 1: 最近在 [46] 中, 研究了分散式 LQ 问题, 并将其应用于多区域 HVAC 问题; 该研究还通过在控制结构本身中学习偏置参数, 处理了由未知扰动源 (室外温度和热增益) 导致的漂移/偏置项的影响。我们的方法在精神上类似, 但我们不是学习控制偏置项, 而是学习不依赖于控制、出现在学习方程中的偏置项。这使得渐近温度跟踪 (改善热舒适性) 成为可能, 因为偏置估计中的误差不会显式地出现在控制中。然而, 我们的多区域实验设置仅限于独立区域控制, 因为它没有考虑区域间相互作用, 而这将涉及集中式/分散式表述。

我们继续分析 Algorithm 1 下的系统行为。对于两个区域以及两个数据集 S1 和 S2, 我们发现所学习的控制器往往会产生较高的超调。然而, 在 20 分钟内, 跟踪响应紧密跟随参考轨迹, 相比手动调谐控制器有轻微改进。这归因于热舒适性与设定点偏差之间相对权重的特定选择。显然, 不同的成本度量将产生不同的行为, 并且可以适应用户需求。在其余区域中也观察到了类似行为, 这些区域也使用了相同的成本函数参数。学到的控制增益的数值汇总于 Table III。

接下来, 我们分析高斯探索对参数收敛的影响。在本研究中, 我们考虑了不同方差的高斯信号来生成不同的数据集。使用零均值高斯噪声获得了两个数据集 G1 和 G2 (每个区域均如此), 其中 Zone 1 的标准差为 0.25 和 0.5, Zone 2 的标准差为 1.25 和 1.5。不同高斯噪声探索下的预学习行为如 Fig. 11 (Zone 1) 和 Fig. 14 (Zone 2) 所示。在两个高斯数据集 G1 和 G2 下, Zone 1 的已学习控制器的学习后响应与使用正弦探索获得的响应相当, 如 Fig. 12 所示。如 Fig. 15 所示, Zone 2 在数据集 G1 下表现出略高的振荡响应; 然而, 在数据集 G2 下观察到改进的响应。与正弦数据集 S1 和 S2 下的参数收敛结果相比, 我们发现, 在高斯数据集 G1 和 G2 下也实现了收敛, 如 Fig. 13 (Zone 1) 和 Fig. 16 (Zone 2) 所示。然而, 与正弦数据集下的偏差相比, 我们发现迭代的收敛对高斯噪声的标准差更为敏感。收敛有时在较少的迭代次数内发生, 但在较高噪声下也遇到了不收敛 (Table III 中的 XX 项表示不收敛)。

已学习控制增益的汇总如 Table III 所示。将 RL 结果与手动调谐的 PI 控制 (调谐为在确保快速收敛的同时保持较小的超调) 进行比较后, 我们发现 RL 结果往往具有更大的

TABLE III 不同求解器、探索和数据集下学习得到的控制增益总结

求解器、探索和数据集	Zone 1	Zone 2	Zone 3	Zone 4
Without Bias Compensation (S1)	[−14.5 −6.1]	[−13.8 −6.5]	[−5.2 −5.1]	[−4.5 −4.9]
Without Bias Compensation (S2)	[−16.8 −11.7]	[−17.0 −12.6]	[−16.6 −12.9]	[−15.9 −12.2]
Batch LS, Sinusoidal (S1)	[15.4 9.5]	[19.7 9.7]	[22.7 13.2]	[24.2 13.6]
Batch LS, Sinusoidal (S2)	[19.4 10.9]	[21.2 10.9]	[14.9 9.7]	[19.1 10.4]
RLS, Sinusoidal (S1)	[15.4 9.5]	[19.7 9.7]	[22.7 13.2]	[24.2 13.6]
RLS, Sinusoidal (S2)	[19.4 10.9]	[21.2 10.9]	[14.9 9.7]	[19.1 10.4]
RLS, Gaussian (G1)	[21.5 11.8]	[33.3 14.9]	[30.5 16.9]	[30.8 14.9]
RLS, Gaussian (G2)	[16.4 10.58]	[20.3 11.0]	[X X]	[10.8 8.4]




Fig. 5. 使用数据集 S1 (左) 和 S2 (右) 的 Zone 1 预学习阶段。




Fig. 6. 使用数据集 S1 (左) 和 S2 (右) 时 Zone 1 在 RLS 规则下的学习后响应。

超调但具有更小的调节时间。对此的一种解释是，奖励函数被选择为相较于设定点偏差，对热跟踪赋予更大的权重。这会导致更高的增益，对应于一种更激进的响应，以在较短时间内最小化误差。




Fig. 7. 使用数据集 S1 (左) 和 S2 (右) 时 Zone 1 在 RLS 规则下的参数收敛。




Fig. 8. 使用数据集 S1 (左) 和 S2 (右) 的 Zone 2 预学习阶段。

尽管所有区域的尺寸相似，我们发现对于相同的代价函数，Zone 3 和 Zone 4 往往具有更高的增益。这可能是由于实验室设计的细节以及其他耦合来源所致。探索信号的类型和幅值也会影响增益，因为 RL 算法在很大程度上依赖于数据集的质量和探索信号的性质。除少数例外情况外，收敛是成功的。特别地，当高斯噪声的标准差为 2.5 时发生了不收敛。当控制输入中的探索变得更加占主导地位时，系统设备可能开始在受约束区域运行，或表现出非线性行为，在这种情况下




Fig. 9. 使用数据集 S1 (左) 和 S2 (右) 时 Zone 2 在 RLS 规则下的学习后响应。




图 12. 使用数据集 G1 (左) 和 G2 (右) 时, Zone 1 在 RLS 规则下的学习后响应。




图 10. 使用数据集 S1 (左) 和 S2 (右) 时, Zone 2 在 RLS 规则下的参数收敛。




图 13. 使用数据集 G1 (左) 和 G2 (右) 时, Zone 1 在 RLS 规则下的参数收敛。




图 11. 使用数据集 G1 (左) 和 G2 (右) 时, Zone 1 的预学习阶段。




Fig. 14. 使用数据集 G1 (左) 和 G2 (右) 的 Zone 2 预学习阶段。

我们规定的控制结构将不再成立。因此,在 RL 算法中谨慎选择探索至关重要,这是一个取决于应用的考虑因素。在我们的实验中,我们发现,当探索幅值变化时,正弦探索会导致参数估计的偏差较小。另一方面, Gaussian 探索的变化有时会导致参数估计出现较大变化。在其中一个

区域中,当偏差较高时也遇到了不收敛。

Table IV 给出了在名义上经过仔细调节的 PI 控制器和不同学习数据集 (正弦、Gaussian) 下的 RL 控制器针对不同区域的均方跟踪误差 (MSE) 总结。总体而言,与不同探索条件下的学习控制器相比,手动 PI 控制器表现出更小的 MSE。这是因为所有 RL 控制器都采用较高取值的权重矩阵 Q 进行设计,该矩阵基于持续时间进行惩罚




Fig. 15. 使用数据集 G1 (左) 和 G2 (右) 时, Zone 2 在 RLS 规则下的学习后响应。




Fig. 16. 使用数据集 G1 (左) 和 G2 (右) 时, Zone 2 在 RLS 规则下的参数收敛。

TABLE IV 均方跟踪误差汇总

控制器/探索	Zone 1	Zone 2	Zone 3	Zone 4
Baseline PI	0.1214	0.0829	0.1122	0.1032
无偏差补偿 (S1)	不稳定	不稳定	不稳定	不稳定
无偏差补偿 (S2)	不稳定	不稳定	不稳定	不稳定
RLS, 正弦 (S1)	0.4943	0.1930	0.3747	0.2624
RLS, 正弦 (S2)	0.1821	0.1176	0.1374	0.1696
RLS, Gaussian (G1)	0.2448	0.2108	—	—
RLS, Gaussian (G2)	0.1760	0.1150	—	—

瞬态过程, 因此以超调为代价实现了更短的瞬态过程。然而, 这种超调会直接影响 MSE。另一方面, 手动 PI 和自动 RL 控制器可以实现相同的稳态性能, 因为一旦学习瞬态过程结束, 控制器就遵循 PI 结构。

VI. 结论

本文介绍了一种结构化强化学习算法在多区域 HVAC 系统区域级控制中的实现。开发了一种偏差补偿 Q-learning 方案, 该方案考虑了

不可测扰动的影响。所提出的 Q-learning 算法与 HVAC 区域而非仿真模型进行交互, 并采用二次奖励函数来考虑跟踪误差和设定点偏差。通过利用控制结构并复用过去系统交互中的数据, 由于学习方程中明确定义的二次参数化以及先验确定的控制结构, 训练数据集的规模和学习时间得以减少。对各种探索信号的全面分析表明, 学习得到的控制参数以及随之而来的学习后性能取决于所采用训练数据集的质量。什么构成高质量数据集取决于系统的状态空间和动作空间被探索得有多全面。然而, 在实践中满足这些要求的充分条件目前尚不清楚。在我们的研究中, 我们发现, 虽然参数估计的收敛几乎总是能够得到保证, 但与高斯探索相比, 正弦探索会导致最终估计中的偏差更小。与传统 PI 相比, RL 算法提供了将奖励函数定制为指定成本的灵活性。RL 方法的自适应能力使我们能够改变成本要求, 这将促使 RL 算法针对新的规范重新学习控制。

REFERENCES

[1] J. Mei, Z. Y. Lu, J. H. Hu, and Y. L. Fan, “直膨式空调系统的节能最优保成本间歇切换控制,” *IEEE/CAA J. Autom. Sinica*, vol. 8, no. 11, pp. 1852–1866, Nov. 2020.

[2] N. E. Klepeis, W. C. Nelson, W. R. Ott, J. P. Robinson, A. M. Tsang, P. Switzer, J. V. Behar, S. C. Hern, and W. H. Engelmann, “国家人类活动模式调查 (NHAPS): 用于评估环境污染物暴露的资源,” *J. Exp. Sci. Environ. Epidemiol.*, vol. 11, no. 3, pp. 231–252, May–Jun. 2001.

DOE, “能源技术与研究机会评估,” in *Proc. AIChE Annu. Meeting*, 2015. [3]

[4] S. Privara, J. Široký, L. Ferkl, and J. Cigler, “建筑供暖系统的模型预测控制: 首次经验,” *Energy Build.*, vol. 43, no. 2–3, pp. 564–572, Feb.–Mar. 2011.

[5] Y. Y. Fu, S. C. Xu, Q. Zhu 和 Z. Q’Neill, “用于建筑控制性能比较的容器化框架: Model predictive control 与 deep reinforcement learning control 的比较,” 载于 *Proc. 8th ACM Int. Conf. Systems for Energy-Efficient Buildings, Cities, and Transportation*, Coimbra, Portugal, 2021, pp. 276–280.

R. S. Sutton 和 A. G. Barto, *Reinforcement Learning: An Introduction*. Cambridge, USA: MIT Press, 1998. [6]

[7] M. M. Ha, D. Wang 和 D. R. Liu, “具有新型稳定性分析的折扣迭代自适应评价设计用于跟踪控制,” *IEEE/CAA J. Autom. Sinica*, vol. 9, no. 7, pp. 1262–1272, Jul. 2022.

[8] G. Geng 和 G. M. Geary, “HVAC 系统中 PID 控制器的性能与整定,” 载于 *Proc. IEEE Int. Conf. Control and Applications*, Vancouver, Canada, 1993, pp. 819–824.

[9] R. S. Sutton, A. G. Barto 和 R. J. Williams, “强化学习是直接自适应最优控制,” *IEEE Control Syst. Mag.*, vol. 12, no. 2, pp. 19–22, Apr. 1992.

M. J. Han, R. May, X. X. Zhang, X. R. Wang, S. Pan, D. Yan 和 Y. Jin, “一种用于改善居住者的新型强化学习方法 [10]

- 通过窗户开启和关闭实现舒适性,” *Sustain. Cities Soc.*, vol. 61, p. 102247, Oct. 2020.
- [11] P. Fazenda, K. Veeramachaneni, P. Lima, and U.-M. O'Reilly, “使用强化学习优化 HVAC 系统中的居住者舒适性和能源使用,” *J. Ambient Intell. Smart Environ.*, vol. 6, no. 6, pp. 675–690, Jan. 2014.
- [12] A. Overgaard, B. K. Nielsen, C. S. Kallensee, and J. D. Bendtsen, “使用带流量变量资格迹的强化学习进行混合回路控制,” in *Proc. IEEE Conf. Control Technology and Applications*, Hong Kong, China, 2019, pp. 1043–1048.
- [13] T. S. Wei, Y. Z. Wang, and Q. Zhu, “用于建筑 HVAC 控制的深度强化学习”, 见 *Proc. 54th ACM/EDAC/IEEE Design Automation Conf.*, Austin, USA, 2017, pp. 1–6.
- [14] E. Barrett and S. Linder, “自主 HVAC 控制, 一种强化学习方法”, 见 *Proc. Joint European Conf. Machine Learning and Knowledge Discovery in Databases*, Porto, Portugal, 2015, pp. 3–19.
- [15] G. T. Costanzo, S. Iacovella, F. Ruelens, T. Leurs, and B. J. Claessens, “建筑供暖系统数据驱动控制的实验分析”, *Sustain. Energy Grids Netw.*, vol. 6, pp. 81–90, Jun. 2016.
- [16] Z. Wang and T. Z. Hong, “用于建筑控制的强化学习: 机遇与挑战”, *Appl. Energy*, vol. 269, p. 115036, Jul. 2020.
- [17] J. X. Zhang, K. W. Li, and Y. M. Li, “具有输入和状态约束的严格反馈系统基于输出反馈的简化优化反步控制”, *IEEE/CAA J. Autom. Sinica*, vol. 8, no. 6, pp. 1119–1132, Jun. 2021.
- [18] Y. J. Chen, L. K. Norford, H. W. Samuelson, and A. Malkawi, “通过强化学习实现自然通风的 HVAC 和窗户系统最优控制”, *Energy Build.*, vol. 169, pp. 195–205, Jun. 2018.
- [19] G. P. Henze 和 R. H. Dodier, “并网独立光伏系统的自适应最优控制”, *J. Sol. Energy Eng.*, vol. 125, no. 1, pp. 34–42, Feb. 2003.
- [20] L. Yang, Z. Nagy, P. Goffin 和 A. Schlueter, “用于低火用建筑最优控制的强化学习”, *Appl. Energy*, vol. 156, pp. 577–586, Oct. 2015.
- [21] K. Dalamagkidis, D. Kolokotsa, K. Kalaitzakis 和 G. S. Stavrakakis, “用于建筑节能与舒适性的强化学习”, *Build. Environ.*, vol. 42, no. 7, pp. 2686–2698, Jul. 2007.
- [22] C. X. Guan, Y. Z. Wang, X. Lin, S. Nazarian 和 M. Pedram, “基于强化学习的住宅储能系统控制以最小化电费”, 见 *Proc. 12th Annu. IEEE Consumer Communications and Networking Conf.*, Las Vegas, USA, 2015, pp. 637–642.
- [23] S. Y. Zhou, Z. J. Hu, W. Gu, M. Jiang 和 X.-P. Zhang, “基于人工智能的智能能源社区管理: 一种强化学习方法”, *C SEE J. Power Energy Syst.*, vol. 5, no. 1, pp. 1–10, Mar. 2019.
- [24] Y. Y. Ran 和 M. H. Jun, “使用深度强化学习进行空间制冷的基于性能的热舒适控制 (PTC C)”, *Energy Build.*, vol. 203, p. 109420, Nov. 2019.
- [25] B. Sun, P. B. Luh, Q.-S. Jia, and B. Yan, “Event-based optimization within the lagrangian relaxation framework for energy savings in HVAC systems”, *IEEE Trans. Autom. Sci. Eng.*, vol. 12, no. 4, pp. 1396–1406, Oct. 2015.
- [26] Y. Zhang and M. van der Schaar, “Structure-aware stochastic load management in smart grids,” 发表于 *Proc. IEEE INFOCOM 2014-IEEE Conf. Computer Communications*, Toronto, Canada, pp. 2643–2651.
- [27] B.-G. Kim, Y. Zhang, M. van der Schaar, and J.-W. Lee, “Dynamic pricing and energy consumption scheduling with reinforcement learning,” *IEEE Trans. Smart Grid*, vol. 7, no. 5, pp. 2187–2198, Sept. 2016.
- [28] D. Bertsekas, “Multiagent reinforcement learning: Rollout and policy iteration,” *IEEE/CAA J. Autom. Sinica*, vol. 8, no. 2, pp. 249–272, Feb. 2021.
- [29] K. G. Vamvoudakis, H. Modares, B. Kiumarsi, and F. L. Lewis, “Game theory-based control system algorithms with real-time reinforcement learning: How to solve multiplayer games online,” *IEEE Control Syst. Mag.*, vol. 37, no. 1, pp. 33–52, Feb. 2017.
- J. Huang, 《Nonlinear Output Regulation—Theory and Applications》, Philadelphia, USA: SIAM, 2004. [30]
- [31] Y. J. Peng, Q. Chen, and W. J. Sun, “未知离散时间线性系统 H_∞ 跟踪控制的强化 Q-learning 算法,” *IEEE Trans. Syst. Man Cybern. Syst.*, vol. 50, no. 11, pp. 4109–4122, Nov. 2020.
- [32] C. Chen, F. L. Lewis, K. Xie, S. L. Xie, and Y. L. Liu, “异构多智能体系统自适应最优输出同步的离策略学习,” *Automatica*, vol. 119, p. 109081, Sept. 2020.
- [33] B. S. Lian, W. Q. Xue, F. L. Lewis, and T. Y. Chai, “对抗环境中连续时间线性系统的鲁棒逆 Qlearning,” *IEEE Trans. Cybern.*, vol. 52, no. 12, pp. 13083–13095, Dec. 2022.
- [34] B. S. Lian, W. Q. Xue, F. L. Lewis, and T. Y. Chai, “对抗学博弈的逆强化学习,” *IEEE Trans. Neural Netw. Learn. Syst.*, 2021. DOI: 10.1109/TNNLS.2021.3114612
- [35] B. Tashtoush, M. Molhim, and M. Al-Rousan, “用于控制分析的 HVAC 系统动态模型,” *Energy*, vol. 30, no. 10, pp. 1729–1745, Jul. 2005.
- F. L. Lewis and V. L. Syrmos, 《最优控制》。第 2 版。Chichester, UK: John Wiley & Sons, 1995. [36]
- [37] S. A. A. Rizvi, A. J. Pertzborn 和 Z. L. Lin, “基于强化学习的在不可测扰动下的最优跟踪控制及其在 HVAC 系统中的应用,” *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 33, no. 12, pp. 7523–7533, Dec. 2022.
- [38] S. J. Bradtke, B. E. Ydstie 和 A. G. Barto, “使用策略迭代的自适应线性二次控制,” 发表于 *Proc. American Control Conf.*, Baltimore, USA, 1994, pp. 3475–3479.
- [39] Z. Chen 和 N. Li, “一种基于最优控制的分布式强化学习框架, 用于多智能体网络的一类非凸目标泛函,” *IEEE/CAA J. Autom. Sinica*, 2022. DOI: 10.1109/JAS.2022.105992
- G. Tao, 《自适应控制设计与分析》。Hoboken, USA: WileyInterscience, 2003. [40]
- [41] C. H. Liu, F. Zhu, Q. Liu 和 Y. C. Fu, “具有自动子目标识别的分层强化学习,” *IEEE/CAA J. Autom. Sinica*, vol. 8, no. 10, pp. 1686–1696, Oct. 2021.
- [42] IBAL Overview, National Institute of Standards and Technology. [Online]. Available: <https://www.nist.gov/el/energy-and-environment-division-73200/intelligent-buildings-agents-project/ibal-overview>
- [43] A. J. Pertzborn, “智能建筑智能体实验室: 水力系统设计,” U.S. Department of Commerce, National Institute of Standards and Technology, 2016. [Online]. Available: <https://doi.org/10.6028/NIST.TN.1933>
- [44] A. J. Pertzborn and D. A. Veronica, “智能建筑代理实验室: 空气系统设计,” U.S. Department of Commerce, National Institute of Standards and Technology, 2016. [Online]. Available: <https://doi.org/10.6028/NIST.TN.2025>
- [45] A. J. Pertzborn and D. A. Veronica, “智能建筑代理实验室中的基准控制系统,” U.S. Department of Commerce, National Institute of Standards and Technology, 2021. [Online]. Available: <https://doi.org/10.6028/NIST.TN.2178>
- [46] Y. Y. Li, Y. J. Tang, R. Y. Zhang, and N. Li, “用于分散式线性二次控制的分布式强化学习: 一种无导数策略优化方法,” *IEEE Trans. Autom. Control*, vol. 67, no. 12, pp. 6429–6444, Dec. 2022.

Syed Ali Asad Rizvi (Member, IEEE) 于2012年获得巴基斯坦 NED University of Engineering and Technology 的 Institute of Industrial Electronics Engineering 工业电子学 B.E. 学位, 于2014年获得巴基斯坦 National University of Sciences and Technology 电气工程 M.S. 学位, 并于2020年获得美国 University of Virginia 电气工程 Ph.D. 学位。他曾是美国 National Institute of Standards and Technology (NIST) 的博士后研究员 (2020 - 2021)。他目前是美国 Tennessee Technological University 电气与计算机工程系的助理教授。他目前的研究兴趣包括最优控制、强化学习、分布式学习与控制, 以及它们在自主系统中的应用, 包括自动驾驶车辆、建筑 HVAC 系统、能源系统和电力传动。



Amanda J. Pertzborn 获得 University of Wisconsin-Madison 的 Ph.D. 学位。她目前是美国 National Institute of Standards and Technology (NIST) 建筑能源与环境部 Intelligent Building Agents 项目的 PI。她的研究重点是供暖、通风与空气调节 (HVAC) 系统的智能控制。

Zongli Lin (Fellow, IEEE) 是 University of Virginia 工程与应用科学学院 Ferman W. Perry 教授, 以及电气与计算机工程教授。他于1983年获得厦门大学数学与计算机科学 B.S. 学位, 于1989年获得中国空间技术研究院自动控制工程硕士学位, 并于1994年获得美国 Washington State University 电气与计算机工程 Ph.D. 学位。他目前的研究兴趣包括非线性控制、鲁棒控制和控制应用。他曾任 IEEE Transactions on Automatic Control (2001 - 2003)、IEEE/ASME Transactions on Mechatronics (2006 - 2009) 和 IEEE Control Systems Magazine (2005 - 2012) 的副编辑。他曾当选为 IEEE Control Systems Society Board of Governors 成员 (2008 - 2010, 2019 - 2021), 并曾担任 IEEE Control Systems Society Technical Committee on Nonlinear Systems and Control 主席 (2013 - 2015)。他曾在多个会议的运行委员会任职。他曾担任 2018 American Control Conference 的程序主席, 以及分别于2012年和2018年举行的第13届和第16届 International Symposium on Magnetic Bearings 的大会主席。他目前在多个期刊和丛书的编委会任职, 包括 Automatica, Systems & Control Letters 和 Springer/Birkhauser 丛书 Control Engineering。他是 IEEE、CAA、International Federation of Automatic Control (IFAC)、American Association for the Advancement of Science (AAAS) 的 Fellow。